

MODELO DE PROPENSIÓN A COMPRA

Plan de Pensiones (pension_plan)

Informe de resultados y recomendación comercial

Priorización de contactos para campaña de cross-selling sobre la cartera actual de clientes

Preparado para: Dirección Comercial y Marketing — easyMoney

Ámbito: Modelo predictivo de propensión — producto pension_plan

Autor del análisis: Miguel — Equipo de Analítica Avanzada

Resumen ejecutivo

easyMoney necesita rentabilizar su base actual de clientes en lugar de seguir invirtiendo en captación. Este análisis desarrolla un modelo de propensión a la contratación del producto **pension_plan** — el de mayor margen de toda la cartera (79% del margen total) — con el objetivo de identificar a qué clientes conviene dirigir una campaña comercial para maximizar la conversión con un presupuesto de contacto limitado.

El modelo ordena a los clientes según su probabilidad de contratar el producto en el próximo mes. Contactando solo al 10% de la base con mayor probabilidad, se capturaría más de la mitad de todas las contrataciones reales esperadas.



Recomendación

Priorizar el contacto comercial en el 10-30% superior de clientes según el ranking del modelo, donde se concentra la práctica totalidad del valor de la campaña. El análisis muestra además que la **actividad del cliente en la app** es, con diferencia, el mejor predictor de propensión — por encima del perfil demográfico o del canal de captación — lo que sugiere que activar clientes inactivos puede ser tan rentable como la propia segmentación de la campaña.

1. Contexto y enfoque

El objetivo del modelo es predecir qué clientes, entre los que hoy no tienen *pension_plan*, tienen mayor probabilidad de contratarlo el próximo mes. Esto permite a los equipos comercial y de marketing dirigir el esfuerzo de contacto hacia el segmento con mayor retorno esperado, en lugar de campañas masivas sin priorización.

Definición del evento a predecir

Se considera una contratación nueva cuando el cliente no tenía el producto el mes anterior y sí lo tiene el mes en curso — es decir, adquisición real, no simple tenencia continuada.

Variables utilizadas

El modelo usa únicamente información disponible en el momento real de decisión: variables demográficas (edad, salario, género) y de comportamiento (segmento comercial, canal de entrada, actividad en la app, número de productos contratados), todas referidas al mes anterior al de la posible contratación. Esto evita usar información que en la práctica no estaría disponible al lanzar una campaña real.

Validación temporal

Al tratarse de datos mensuales por cliente, la partición de los datos en entrenamiento, prueba y validación se realizó por fecha y no de forma aleatoria, evitando que el modelo aprenda con información de meses posteriores al que intenta predecir — un error habitual que sobreestima el rendimiento real del modelo.

Selección del modelo

Se optó por un árbol de decisión por su interpretabilidad directa ante equipos de negocio: permite explicar de forma sencilla qué variables pesan en cada predicción. Se ajustó la complejidad del árbol (profundidad = 7) para maximizar la capacidad predictiva sin caer en sobreajuste sobre los datos de entrenamiento.




Figura 1. Comparación de rendimiento del modelo (AUC) según su nivel de complejidad, en datos de entrenamiento y de prueba.

2. ¿Qué predice mejor la contratación?

Más allá del propio ranking de clientes, el modelo permite identificar qué variables explican mejor la propensión a contratar pension_plan — un insight directamente accionable para el diseño de la campaña.




Figura 2. Importancia relativa de cada variable en las decisiones del modelo.

Hallazgo principal

La **actividad del cliente en la app** explica, ella sola, cerca del 73% del poder predictivo del modelo — muy por delante de la edad (12%), el número de productos ya contratados (6%) o el segmento comercial y canal de entrada (9% combinados). El género no aporta prácticamente nada (0,01%), lo cual es una señal positiva desde el punto de vista de equidad del modelo.

Implicación de negocio: antes de lanzar la campaña, puede ser más rentable invertir en reactivar clientes actualmente inactivos en la app que en afinar la segmentación por edad o canal de entrada — el modelo indica que la actividad es, con diferencia, el factor que más pesa.

3. Rendimiento y fiabilidad del modelo

El modelo se evaluó sobre un mes de datos nunca utilizado en su entrenamiento, para medir su capacidad real de generalización.

	Predicho: No compra	Predicho: Compra
Real: No compra	311.857	104.862
Real: Compra	295	1.979

Tabla 1. Matriz de confusión sobre el mes de prueba. El modelo identifica correctamente al 87% de los clientes que sí contratan el producto (1.979 de 2.274), a costa de marcar como candidatos a un número mayor de clientes que finalmente no compran — un compromiso deliberado y deseable en este tipo de modelos: es preferible sobre-identificar candidatos que dejar pasar oportunidades reales de venta, dado que el coste de un contacto comercial es bajo frente al valor de una conversión.




Figura 3. Curva ROC — a mayor área bajo la curva (AUC = 0,87), mayor la capacidad del modelo para distinguir clientes propensos de los que no lo son.

4. Robustez: comparación con un modelo alternativo

Para contrastar los resultados, se entrenó un segundo modelo (Random Forest, un conjunto de 200 árboles combinados) bajo las mismas condiciones, y se comparó su rendimiento frente al árbol de decisión de referencia.

Métrica	Árbol de decisión	Random Forest
AUC (test)	0,8720	0,8744
Granularidad del ranking (valores de probabilidad distintos)	96	71.682




Figura 4. Comparación de curvas ROC entre ambos modelos.

El modelo alternativo apenas mejora la capacidad predictiva (+0,002 de AUC), confirmando que la señal está bien capturada por el árbol simple — coherente con que una única variable (actividad en la app) concentre la mayor parte del poder predictivo. Sí ofrece un ranking mucho más fino entre clientes (71.682 niveles de probabilidad frente a 96), lo que lo hace preferible si en el futuro se necesita priorizar con más granularidad dentro del propio segmento de alta propensión. Para esta primera fase, se mantiene el árbol de decisión como modelo de referencia por su mayor transparencia ante los equipos de negocio.

5. Impacto esperado en una campaña real

En una campaña real no se contacta a toda la base de clientes, sino a un porcentaje priorizado. Se simuló el resultado de contactar a distintos tramos de clientes ordenados por probabilidad predicha, sobre un mes de datos reservado exclusivamente para esta validación final.



Detalle por tramo de propensión

La siguiente tabla divide a los clientes en diez tramos iguales (deciles) según su probabilidad predicha, mostrando la conversión real observada en cada uno.

Tramo (decil)	Clientes	Contrataciones reales	Conversión	Mejora vs. azar	% acumulado capturado
1 (más propensos)	42.217	1.535	3,64%	x5,50	55,0%
2	42.216	632	1,50%	x2,26	77,6%
3	42.216	358	0,85%	x1,28	90,5%
4	42.216	135	0,32%	x0,48	95,3%
5	42.216	48	0,11%	x0,17	97,0%
6-10 (menos propensos)	211.080	103	0,05%	< x0,08	100,0%




Figura 5. Mejora de conversión ("lift") por tramo de propensión, frente a un contacto no dirigido (línea de referencia = 1).

6. Conclusiones y recomendación

El modelo permite multiplicar por 5 a 7 veces la conversión de una campaña de pension_plan frente a un contacto no dirigido, concentrando prácticamente todo el valor en el 10-30% superior de la base ordenada por probabilidad. Contactar más allá de ese tramo aporta muy poco valor incremental y diluye la eficiencia de la campaña.

Recomendaciones concretas

- Dirigir la campaña de pension_plan al 10-30% superior de clientes elegibles según el ranking del modelo, priorizando el decil 1 si el presupuesto de contacto es limitado.
- Explorar una acción previa o paralela de activación de clientes inactivos en la app, dado que es la variable con mayor peso predictivo sobre la propensión a contratar.
- Adoptar el modelo Random Forest en producción si se requiere un ranking más fino dentro del segmento de alta propensión, manteniendo el árbol de decisión como herramienta de explicación ante negocio.
- Actualizar el modelo de forma periódica (mensual o trimestral) a medida que se disponga de nuevos datos de actividad y contrataciones, para mantener su capacidad predictiva.

Este análisis se ha desarrollado como parte de un proyecto conjunto de analítica avanzada sobre la cartera de clientes de easyMoney. Un segundo modelo de propensión, sobre el producto em_acount, sigue la misma metodología y está disponible como informe complementario.